

Tugas 12: Implementasi PCA pada Dataset Breast Cancer

Ahmad Azka Ridha - 0110222062

Teknik Informatika, STT Terpadu Nurul Fikri, Depok

*E-mail: ahma22062ti@student.nurulfikri.ac.id

Abstract. Pada tugas ini saya melakukan implementasi PCA pada dataset Breast Cancer yang diambil dari Kaggle

1. Import Library & Load Dataset

Kita memulai dengan memuat dataset dan library standar untuk pemrosesan data serta PCA.

```
[ ] import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt

df = pd.read_csv('https://docs.google.com/uc?export=download&id=19GEiOGuS-xXfu4Mems3PEXuWIRuz12L3')
df.head()
```

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	...	texture_worst	perimeter_worst	area_
0	842302	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	...	17.33	184.60	
1	842517	M	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	...	23.41	158.80	
2	84300903	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	...	25.53	152.50	
3	84348301	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	...	26.50	98.87	
4	84358402	M	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	...	16.67	152.20	

5 rows x 33 columns

2. Membersihkan Data

Dataset punya kolom id dan Unnamed : 32 yang tidak berguna dan akan kita hapus. Pembersihan diperlukan agar PCA tidak dipengaruhi kolom yang tidak relevan.

```
[ ] df = df.drop(['id', 'Unnamed: 32'], axis=1, errors='ignore')
```

3. Pisahkan Fitur dan Label

PCA hanya bekerja untuk fitur numerik, jadi label diagnosis dipisahkan.

```
1 X = df.drop('diagnosis', axis=1)
   y = df['diagnosis']
```

4. Standarisasi Data (Wajib untuk PCA)

PCA sensitif terhadap skala data. Standarisasi ini membuat semua fitur berada pada skala yang sama.

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

5. Menerapkan PCA

PCA mencoba mencari arah variansi terbesar → hasilnya dimensi baru yang lebih ringkas.

```
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
```

6. Melihat Besarnya Variansi yang dijelaskan PCA

Mengetahui berapa persen informasi dataset yang masih dipertahankan setelah direduksi.

```
▶ pca.explained_variance_ratio_
... array([0.44272026, 0.18971182])
```

7. Visualisasi PCA (Scatter Plot)

Mengetahui berapa persen informasi dataset yang masih dipertahankan setelah direduksi.

